

CSDN

博客学院下载图文课TinyMind论坛APP问答商城VIP会员活动招聘ITeyeGitChat

搜博主文章

13

5

转

Kaggle 首战拿银总结 | 入门指导 (长文、干货)

2017年05月18日 14:55:17 数据娃娃 阅读数：15467


转自：第一次参加Kaggle拿银总结

作者：ScarletPan

另一篇文章：从0到1走进 Kaggle


我的比赛代码已经放到github --> [Kaggle-Rental-Listing-Inquireies](#)

在这篇博客开始之前，我必须感谢导师给我提供服务器资源，@Fenix Lin学长从他自身经验出发耐心地为我解答一些困惑，@Wille学长的博文如何在Kaggle 首战中进入前 10%帮助入门，以及广大Kaggler的无私分享，我确实在Kaggle举行的这场Rental Listing inquiries比赛中收益良多知识。作为第一次参加比赛，获得了Top 5%的成绩已经让我非常满意了。



ScarletPan

undergraduate at Zhejiang University  
杭州市, 浙江省, 中国  
Joined a year ago · last seen in the past day  
<http://scarletpan.github.io>



Competitions Contributor

Home

Competitions (1)

Kernels (0)


Discussion (6)

Datasets (0)

More

Edit Profile

Competitions Summary



Competitions Contributor

Unranked

0

1

0

Competitions: 1

Solo: 1 (100%)

Team: 0

Level up to Competitions Expert

2 bronze medals


1 competitions entered

Sort by Best Results

Completed


Active

Tutorial



Two Sigma Connect: Rental Listing Inquiries

3 days ago · Top 5%  
95 entries as a solo competitor



105<sup>th</sup>  
of 2489

No more competitions to show

这篇文章的目的是介绍自己第一次参加Kaggle的心历路程，总结遇到的问题和解决思路，为自己以后参赛做准备。同时这篇文章也可以作为一个初学者Kaggle的参考，如果想要在入门kaggle的时候拿到一个好的名次，可以参考我的一些方法实践。本文可以随意转载，但务必注明出处和作者，并且发邮件myscarlet@sina.com通知我。

## 初识Kaggle

### 什么是Kaggle

从刚接触machine learning的时候就有在学长口中、博文中、社区中听到过它的名字，当初我对它的理解还比较浮浅，只是知道是一个数据比赛的平台的数据集，比如大二寒假做的第一个ML练手项目就是一个用word2vec进行情感分析的Tutorial级比赛Bag of Words Meets Bags of Popcorn，并且写了report。这过程中只用到了教程和数据集。

后来重新接触Kaggle才发现，它的价值所在是各种高质量的比赛，以及每场比赛下面的社区讨论（包括比赛中的分享、答疑，和比赛后的top solution）。如果想要获得关于数据挖掘，机器学习实战经验的话，打一场kaggle比赛绝对是一个高回报的工作。

因为还是学生，不知道kaggle比赛究竟是否会为自己求职工作有举足轻重的影响，但是单从Kaggle被google收购一点来看，它会在行业内一点点提升景

### 比赛组织

开发者调查

AI开发者大会日程曝光

告别知识焦虑，即刻启程

1 硬件工程师

2 VMware虚拟机

https://blog.csdn.net/jdbc/article/details/72468001?utm\_source=blogxgwz1

1/8

另外就是奖牌问题，一般来讲在1000+量级的比赛中，top 10+ 0.2%为金牌，5%为银牌，10%为铜牌，[这里有更具体的奖牌发放方式](#)。

### 讨论区

个人认为，如果想在入门Kaggle阶段就获得一个好的成绩的话，关注discussion是非常重要的，会有很多人分享自己的思路、困惑甚至代码和结果。有赛中比较关键的feature可能就是从讨论区中获得的，比如[Two Sigma Connect: Rental Listing Inquiries](#)这场比赛的最后几天，我以为自己特征提取得已没有任何idea了的时候，一个来自讨论区magic feature从天而降，从而使得榜单大变，一夜之间我的排名从70多掉到了120多。

### 数据探索和可视化（EDA）

首先拿到一个比赛题目，你需要下决心是否参加这个比赛，对我个人而言最重要的无非两点 1. 是不是有rank point，也就是奖牌，2. 数据集是否令我感兴趣。数据的探索首先需要你从Kaggle网站上查看数据的简介，并把数据下载下来。比如Rental Listing Inquiries包含了80G的图片数据和几份json文件。

我们将下载下来的train.csv用python pandas 打开，取少量样本进行观测

```
1 import pandas as pd
2 train = pd.read_json("input/train.json")
3 train.sample(2)
```

listing_id	longitude	manager_id	photos	price	street_address
6910594	-73.9927	e97e905f8a821f1446a1bc42f4d8802e	[https://photos.renthop.com/2/6910594_89e705c6...	4250	1 Astor Place
7006854	-73.9882	2d384fd4c8b82700852c62187ca50df	[https://photos.renthop.com/2/7006854_7111fa1b...	4500	104 Second Avenue

抛开图片数据不谈，我们可以看到给定的数据里包含多种多样的feature：

- 数值型feature
  - bathrooms
  - bedrooms
  - price
- 高势集类别（High Categorical）型feature
  - building\_id
  - display\_address
  - manager\_id
  - street\_address
- 时间型feature
  - created
- 地理位置型feature
  - longitude
  - latitude
- 文本feature
  - description
- 稀疏特征集feature
  - features
- id型feature

- [index](#)

我们看到有这么多不同的feature，一看几乎每个feature都有深度挖掘的价值，何况还有80G的图片feature，无疑是让人兴奋的，因此我选择了这个比赛数据集的确让我舒心。

另外一定要搞明白的一件事是这场比赛是一个预测比赛还是分类比赛，我们能看到最重要预测的是用户的interest\_level，分为low，medium，high三级分类问题了。

接下来的是就是对数据进行可视化探索了，我因为是初期参赛的，所以自己做了一份可视化方案，从中可以发现很多有趣的分布、outlier等。在这里推中分享出来的比较好的EDA：

- [Simple Exploration Notebook](#)
- [Two Sigma RentHop EDA](#)
- [Data Exploration Two Sigma Renthop](#)

---

## 提取基础特征+模型训练

有了之前数据探索的基础，我们很快能提取到一些基础的feature，比如数值型feature进行简单的加减乘除，类别型feature用id顺序编码，稀疏特征集用码，时间特征生成年、月、日等。将一些基础的特征转换成相应的输入input\_X矩阵后，再将label也转换成数值形式：

```
1 target_num_map = {'high':0, 'medium':1, 'low':2}
2 y = data["interest_level"].apply(lambda x: target_num_map[x])
```

懂机器学习的人都知道，有了这些(X, y)对，我们就可以进行模型训练了。

我们用cross-validation ( CV ) 的成绩来判断我们本地的实验结果，也就是将 ( X , y ) 训练集拆分成训练和验证集，训练相应分类器对训练集拟合，再行loss的计算来评估模型的好坏。

常见的分类器有Logistic Classifier，SVM，NN softmax，Random Forest等。但是在kaggle上用的比较多的还是一些封装好的库，如sklearn里的各种：鼎鼎的xgboost，最近崭露头角的lightgbm等。

早就听闻xgboost的好用，我就直接在电脑上pip了xgboost，作为我接下来一两个月以来的核心分类器。将原先的 ( X , y ) 对中的训练部分输入xgboost用验证部分predict计算mlogloss。

至此为止，比赛初期的第一个模型就已经训练好了。

---

## 跑出一个能提交的结果

训练完一个比较好的模型之后，就可以对测试集进行预测了，首先将训练集 ( X , y ) 对输入xgboost中重新训练，然后对测试集也像对训练集一样进行测出来的结果按照比赛指定的格式保存到文件（在这里还是建议用pandas），即可提交。

第一次提交意味着你正式进入比赛，提交的结果会在Leader Board上显示你当前的排名，当然这个排名只起到参考作用，因为你提交上去的大部分结果有进行评估。

---

## 特征工程 ( FE )

在一系列的初始操作以后，你就要踏上FE的漫漫长征了。本人断断续续在数据清洗、特征提取上做了约两个多月，在比赛最后一段时间模型融合完毕并寻找、测试新的特征。后期评论中magic feature的出现，让每个人的预测结果好了0.01 ~ 0.02个点。不得不说，特征工程才是Kaggle比赛获胜的关键，初学者耗费大量精力在这上面是没错的。而本博文也是重点想讲一下自己发现新特征的一些心历程。

在对一些基础的特征进行生成之后，我开始了漫长地测试特征的长征路，测试的思路我后来发现并不是很好，因为是通过新增加一个或几个feature，如去了，就增加这个feature，如果cv分数没有上去，就舍弃这个feature，也就是相当于贪心验证。这样做的弊端在于，如果之前被舍弃的feature和之后feature联合在一起才会有正面影响，就相当于你错过了两个比较好的feature。因此特征的选择和联合显得非常关键。

在比赛阶段，花费大量力气去创建一个feature，到头来却选择放弃这个feature的事情很常见，我后期的特征有很多是新添加的，旧有的一些特征并没有来就让我总结一下这场比赛中有哪些“好”的feature，为以后的比赛提供灵感和经验。

- 数值型feature的简单加减乘除

这个乍一看仿佛没有道理可言，但是事实上却能挖掘出几个feature之间的内在联系，比如这场比赛中提供了bathrooms和bedrooms的数量，以及价格price，用户可能会更关心每个卧室的价格，即bathrooms / price，也会关心是不是每个房间都会有一个卫生间bathrooms / price，这些数值型feature之间通过算

了联系，从而挖掘出了feature内部的一些价值，分数也就相应地上去了。

- 高势集类别 ( High Categorical ) 进行经验贝叶斯转换成数值feature

什么是High Categorical的特征呢？一个简单的例子就是邮编，有100个城市就会有几百个邮编，有些房子坐落在同一个邮编下面。很显然随着邮编的增加用简单的one-hot编码显然效果不太好，因此有人就用一些统计学思想（经验贝叶斯）将这些类别数据进行一次map，得到的结果是数值数据。在这人分享了一篇paper里面就提到了具体的算法。详细就不仔细讲了，用了这个encoding之后，的确效果提升了很多。那么这场比赛中哪些数据可以进行encoding呢，只要满足下面几点：1. 会重复，2. 根据相同的值分组会分出超过一定数量（比如100）的组。也就是说building\_id, manager\_id, street\_address都能进行这样的encoding，而取舍就由最后的实验来决定了。


- 时间特征

针对于时间数据来讲，提取年、月、日、星期等可能还是不够的，有另外一些points可以去思考，用户的兴趣跟发布时间的久远是否有关系？可以构造来进行测试：

```
1 data["latest"] = (data["created"] - data["created"].min())
2 data["passed"] = (data["created"].max() - data["created"])
```

可以看到latest指的是从有数据开始到该房创建为止一共过去了多少时间，而passed则是该房记录创建为止到最后有记录的时候一共过去了多少时间。

另外针对于时间特征还可以用可视化的方式来与其他特征建立联系，比如我们观察listing\_id与时间变化到底有怎样的联系，能够绘制出如下的图来：



可能简单的相除就能获得很好的结果

- 地理位置特征

想到地理位置，就会想到聚类，一个简单的方式将每个房子划分到同一块区域中去；除了聚类以外，算出几个中心点坐标，计算曼哈顿距离或者欧式距神奇的效果。

- 文本特征

实话说自己是看中这次比赛中有文本数据才参加的，因此在文本挖掘中做了很大的努力，比如提取关键词、情感分析、word embedding聚类之类都尝过都不是很好，对于文本的特征的建议还是去找出一些除了停用词以外的高频词汇，寻找与这个房屋分类问题的具体联系。

- 图片特征

除了最后爆料出来的magic feature(后文会提到)以外，我只用了一个房子有几个照片这个信息。讨论区中都说对于图片特征用CNN提取、简单特征提取不是很好。

- 稀疏特征集

其实就相当于一系列标签，不同标签的个数也是挺多的，本次比赛我只是简单地采用了counterEncoding的方式进行one-hot编码。值得一提的是，有些并行的，比如cat allowed 和 dog allowed可以合并成为 pet allowed，我在这场比赛中手工地合并了一些feature数据，最终结果略微有所提升。

- 特征重要程度 ( feature importance )

在树结构的分类器比如randomforest、xgboost中最后能够对每个特征在分类上面的重要程度进行一次评估。这时候如果已经选定了一些feature进行训练看feature importance的反馈是非常重要的，比如本场比赛制胜的关键是运用manager\_id这个feature，而它的feature importance反馈结果也是非常高。特征的重新再提取特征，能够发现很多有意思的新特征，这才是用FE打好一场比赛的关键所在。

---

下面列出了一些比赛结束后获胜者分享的idea，这大概是我这场比赛中获益最大的一块地方了。

- Top #1 solution @plantsgo

主要是针对manager\_id生成了非常多的feature。如根据不同时间出现的manager\_id判断一个manager是否活跃（manager与time进行group，manager与building\_id进行group）、平均每天处理多少房子（比值）、活动范围（同个manager掌管房子的最大最小经纬度group），经理（选择bedroom和bathroom作为房子型号指标，把相同房型的均价来衡量经理对于所有房子的开价程度），对经纬度进行聚类再计算每个区域中有多少竞争、一个manager同时经营几个区域、在同个区域中manager的开价水平等。从Top 1选手分享的代码来看，其对于manager的各种处理的确是让人

- Top #2 solution @Faron

从更为经验丰富的选手给出了一些特征提取建议。其中有一类被作者称为"Likelihood Features"，他对High Cardinal Categorical的特征用了一些额外的算其似然值，如 $p(y|\text{manager\_id, bathrooms})$ 等，并且进行了点积操作来算出一个合适的encoding值（类似于先前讨论区中出现的manager\_skills，通过拟合对这些似然估计出来的feature创建了2层嵌套。另外还有一种对我启发比较大的feature是对description出现频率最高的15k单词进行一个one-hot训练，将这个训练出来模型的预测结果作为description的encoding。

- Top #3 solution @Little Boat

其FE的第一部分给出了group的一套方案，类似于我自己FE中的group方法。第二部分使用了magic feature相关的feature，第二部分类似

- Top #9 solution @James Trotman

没有细说，但是列出了一个feature name的详单，希望以后没有idea的时候能从中找到一些insight

- Top #11 solution @KazAnova

KazAnova无疑是这场比赛中的明星选手，他分享了对初学者模型融合比较关键的Stack-Net，以及对最后榜单变动起到决定性作用的magic feature。凡上的Kagglers都要向他致敬。同时在FE这一块，他注意到了数据集中存在很多类似的数据（仅仅在价格上有区别），因此他建立了不同的group，并在创建了很多aggregated features，比如最高的price，平均price等

- Top #12 solution @b.e.s

用到了基于高势集类别数据的group的一些统计量。

- Top #13 solution @qianqian

也是用了很多基于manager\_id group的统计feature。

## 模型调参 ( Grid Search )

模型调参的话，能够在FE完之后为你提升0.001 ~ 0.002分数，因此如何为我们的分类器，比如xgboost选择好正确的参数是非常关键的。

比较常用的是进行Grid Search，从你的输入组合中暴力地搜索cv结果最优的组合。我一般会设定一个learning rate，然后尝试不同的参数组合，取最优search的代价比较高，最好选择一定范围，比如你事先cv的时候知道estimator会在700 ~ 1000的范围内，那就不要search这个范围以外的值了。

## 模型融合

如果你没有idea了的话，就模型融合吧！模型融合是能够快速提高比赛成绩的捷径，现在的比赛几乎没有人不用到这个技巧，通常获胜者会对很多很多合，并且会选择不同的模型融合的方式。这里有一篇非常好的模型融合解析[博文](#)，相信每个看过它的人都会对模型融合有一个清楚的了解

本次比赛中我使用了两种模型融合方式，一种是Averaging，一种是Stacking。

先来说说Stacking，因为这场比赛一名贡献比较大的选手分享了一个叫StackNet的库，作为新手我就直接用了。首先我用我的xgboost cv集交叉预测出feature的一部分放到train data中，再对test data进行预测的结果作为feature的一部分放到test data中，再在第二层上选择了Logistic Classifier，GradientBoostingClassifier，AdaBoostClassifier，NNSoft-maxClassifier，RandomForestClassifier等进行交叉预测，第三层选取了一个randomForest作训练和预测。Stacking主要增多了模型的diversity，使我的成绩上升了至少0.003的量级。

然后是Averaging，之前提到过Stacking需要交叉预测，我就选取了10组随机种子分别对训练集进行10-kfold交叉预测取平均，以及每个fold训练预测的xgboost选取5个随机种子取平均。也就是说，在第一层Stacking的CV集交叉预测时我总共训练了500个模型进行平均。分数的提升大约在0.002左右。

直到比赛结束看了排名靠前的选手的模型融合后，才发现自己对于模型融合只是做了一点微小的工作，提升空间还非常大。详情可以看FE部分分享的s

## Tricks

在这场比赛中有一名在刚开始的两个星期一直遥遥领先的选手爆出这个比赛有个magic feature，大家陷入了疯狂找这个feature的过程中，直到那位分享了选手分享出了这个magic feature：80G图片数据每个文件夹的创建时间，于是榜单大变，我一觉醒来后发现自己掉了很久就发现到了不对劲，便迅速加magic feature疯狂屠榜的大军中，从这里可以看见，一个信息量巨大的feature如果被发现的话，对比赛成绩会带来多么大的影响。

有一些group的feature能够起到非常重要的作用，详细见我比赛后发表的一个小样例[discussion topic](#)。但是一定要防止过拟合。



总结

这篇博文还有一些关键的点没有涉及到，比如数据的清洗，有些数据在记录中似乎是不同的，但是意思是一样的，就应该归位同一个类别，还有就是清等。

对这个比赛的top solution总结得还是没到位，基本没有coding实现他们的idea过。由于课程压力比较大，等到时候空了的时候再好好整理。

另外还有就是需要持之以恒地打这个比赛，因为你以为你idea都没有了，模型调参、融合完毕了的时候，可能大家都找出了另一个"magic feature"，轻奖牌的范围了。

最后，Kaggle is fun!

转型**人工智能**可以吗？一个小测试就让你知道怎么学

机器学习|深度学习|图像处理|自然语言处理|无人驾驶，这些技术都会吗？看看真正的人工智能师都会那些关键技术？年薪比你高多少！

想对作者说点什么？

我来说两句

**那小淮\_92**：您好哈 我看了您的代码 有几个问题想和您交流一下哈 可以加个qq嘛？多谢啦 （5个月前 #5楼）

**weixin\_41708307**：您好！可以和你详细交流一下这个题目么？我是一名数学系的大二学生想做类似的创新项目有很多问题想向您请教！ （7个月前 #4楼）

**床长**：写得不错！我最近也在写一系列的人工智能教程，通俗易懂，无需高等数学基础,教程也力求风趣幽默。点击我的头像浏览教程，最好从序言看起。希望更多的工智能大家庭中，使中国更加强大，使中国人在国外能把头抬的更高！ （8个月前 #3楼）

**schwt**：“因此有人就用一些统计学思想（经验贝叶斯）将这些类别数据进行一个map，得到的结果是数值数据。在这场比赛中有人分享了一篇paper里面就提到了具体

查看 6 条热评

Kaggle入门系列：（三）Titanic竞赛初试身手

1665

本篇文章针对刚刚接触Kaggle的同学，介绍参加Kaggle数据分析竞赛的完整流程，最快速度完成一个比赛。...

来自：王十二的

Kaggle初学者五步入门指南，七大诀窍助你享受竞赛

2.7万

Kaggle初学者五步入门指南，七大诀窍助你享受竞赛 By 机器之心2017年7月22日 14:41 Kaggle 是一个流行的数据...

来自：Slark的博客

从0到1学好区块链开发，一年编程经验学完月薪可达40K+

立即申请试学，成为时代颠覆者

Kaggle正式赛首战top3%分享，小白献给机器学习新手

1986

kaggle首战前3%

来自：weixin\_39940612的博客

kaggle三个入门竞赛教程

1210

1. Titanic（泰坦尼克之灾）中文教程：逻辑回归应用之Kaggle泰坦尼克之灾（点击查看）英文教程：An Interactiv...

来自：mudooo的博客

关于Kaggle入门，看这一篇就够了

1.7万

这次酝酿了很久想给大家讲一些关于Kaggle那点事儿，帮助对数据科学(Data Science)有兴趣的同学们更好的了解...

来自：bbbeoy的专栏

kaggle入门之如何使用

3595

大数据竞赛平台——Kaggle 入门篇 这篇文章适合那些刚接触Kaggle、想尽快熟悉Kaggle并且独立完成一个竞赛项...

来自：mdjxy63的博客

光谷股王8年追涨停铁律“1272”曝光，震惊众人

第六· 爍爍

大数据竞赛平台——Kaggle 入门

15.6万

大数据竞赛平台——Kaggle 入门篇 这篇文章适合那些刚接触Kaggle、想尽快熟悉Kaggle并且独立完成一个竞赛项...

来自：wepon的专栏

Kaggle竞赛入门教程之Kaggle简介（新手向）

2.5万

Kaggle是全球最大的数据科学家汇聚的平台，机器学习高手云集，同时对萌新也很友好。Kaggle网址：https://www....

来自：大家好，我是Utanbo

搭建Linux虚拟机

适合人群：菜鸟级小白学员,章节：第三课：Virtualbox小技巧

https://blog.csdn.net/jdbc/article/details/72468001?utm\_source=blogxgwz1

6/8

### 大数据竞赛平台——Kaggle 入门篇

👁 1059

这篇文章适合那些刚接触Kaggle、想尽快熟悉Kaggle并且独立完成一个竞赛项目的网友，对于已经在Kaggle上参赛...

来自：[春华秋实](#)

#### 相关热词

kaggle招聘   kaggle农业   kaggle账户   kaggle安装   kaggle实验

#### 博主推荐



**THEONE10211024**  
[关注](#)   167篇文章



**v\_JULY\_v**  
[关注](#)   171篇文章



**天天学习\_好好向上**  
[关注](#)   882篇文章



**数据娃掘**

[关注](#)

原创	粉丝	喜欢	评论
99	725	296	117

等级：[博客 7](#)   访问：102万+  
积分：1万+   排名：2359



#### 如何上youtube



#### 最新文章

【收藏】各种乘法的区别“点积、外积、数乘...等”

迁移学习和多任务学习

【ICML2018见闻】迁移学习、多任务学习领域的进展

论文复现|pointer-generator

Tensorflow 国内镜像源 [安装]

#### 个人分类

NLP/DeepLearning	305篇
DataBase	6篇
BigData	43篇
IDE	8篇
Linux	44篇

[展开](#)

#### 归档

2018年10月	1篇
2018年9月	3篇
2018年7月	2篇
2018年6月	36篇
2018年5月	1篇

展开

热门文章

- TensorFlow入门教程集合  
阅读量：65707
- 文本数据的机器学习自动分类方法(上)  
阅读量：40593
- tensorflow自学之前的bigpicture  
阅读量：27505
- 解决MyEclipse开启后总是不停的在Update index  
阅读量：26762
- 文本挖掘  
阅读量：23102

最新评论

- 设置漂亮护眼的eclipse主题风格  
weixin\_43189363：[reply]weixin\_43165391[/reply]
- nlTK-构建和使用语料库-可用于...  
qq\_36512295：转的原文链接没贴么
- 【资源分享】《机器学习&深...  
wellknown\_：链接失效，能不能重新补，或者发一份我邮箱1748424989@qq.com
- nlTK-构建和使用语料库-可用于...  
qq\_36512295：您好，数据的链接失效了？楼主数据能分享下么？万分感谢。
- nlTK-构建和使用语料库-可用于...  
qq\_36512295：[reply]cdm94111[/reply] 你好，你找到新的数据链接了没？有的话能发我下么？万...



联系我们



扫码联系客服



下载CSDN APP

 kefu@csdn.net

 400-660-0108

 QQ客服

 客服论坛

关于我们 招聘 广告服务 网站地图

百度提供站内搜索 京ICP证09002463号

©2018 CSDN版权所有

经营性网站备案信息 网络110报警服务

北京互联网违法和不良信息举报中心

中国互联网举报中心